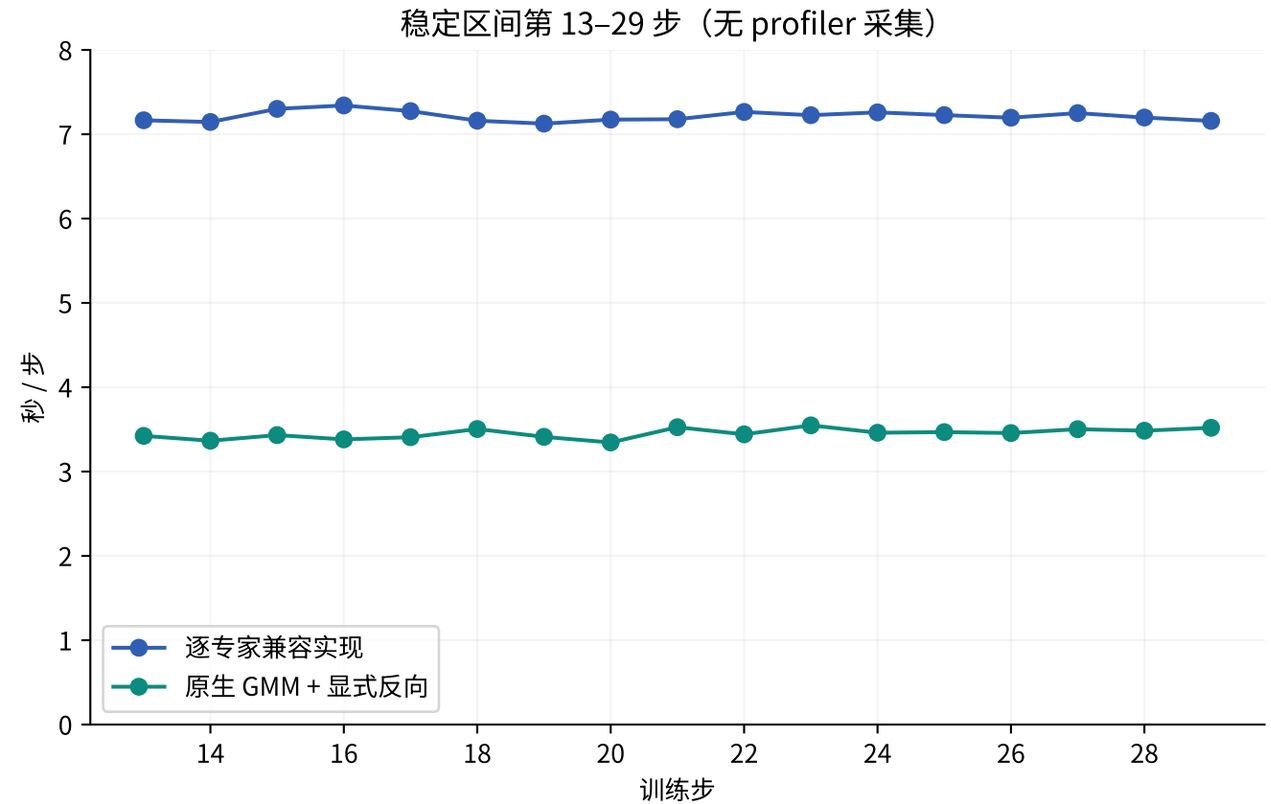
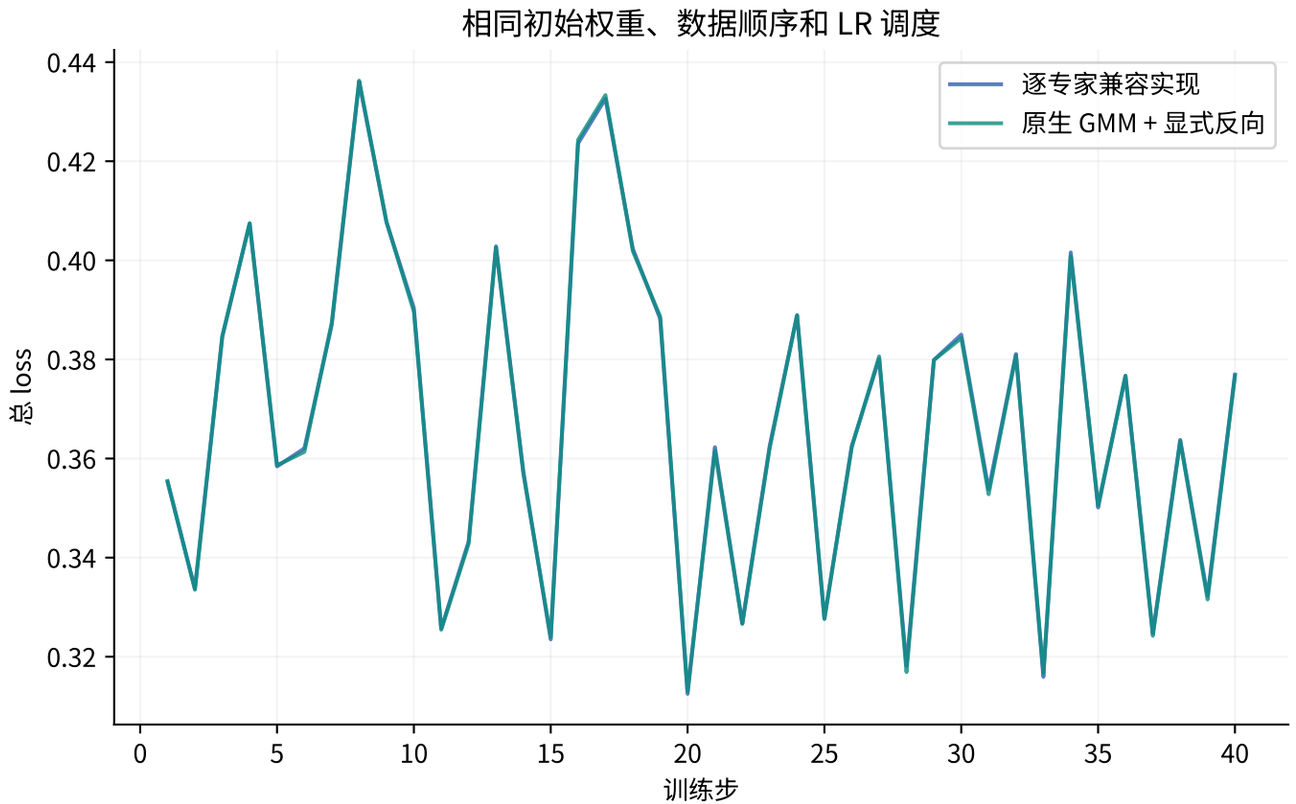
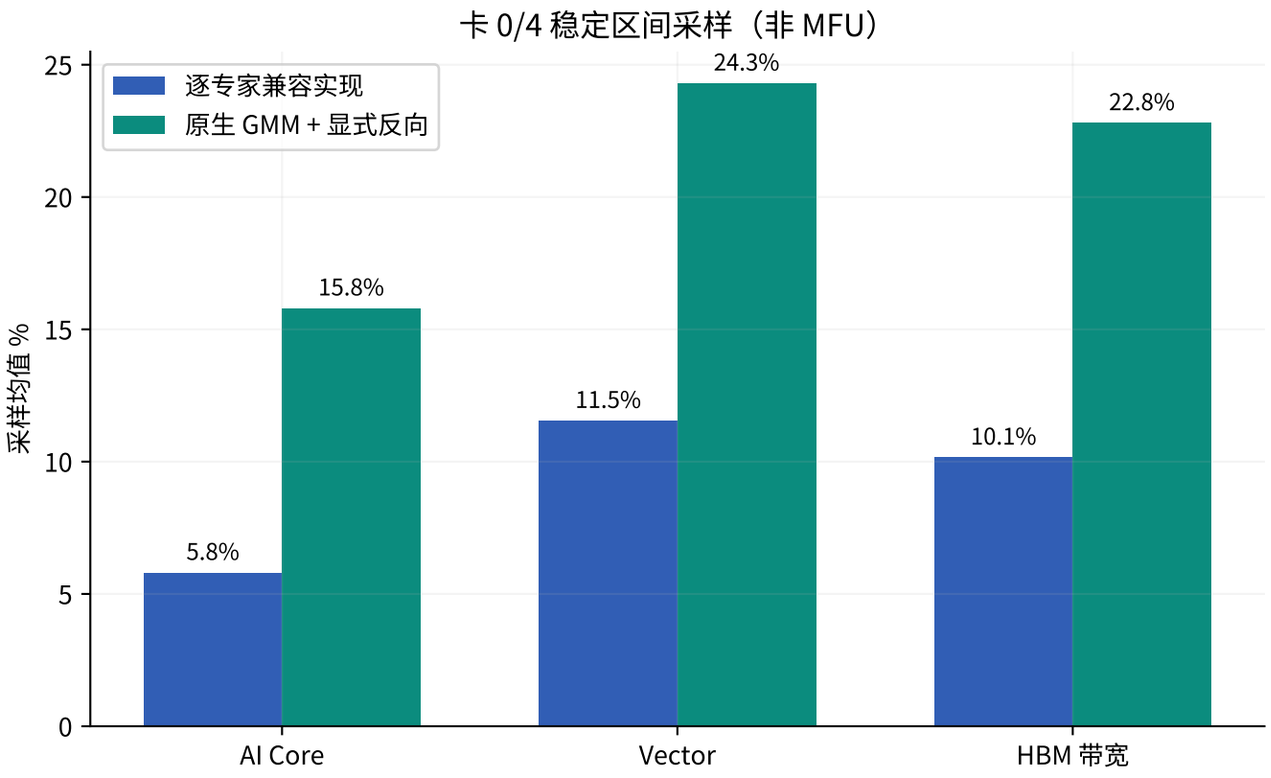
LingBot-VLA　NPU MoE 优化的 8 卡完整模型对照







端到端吞吐提升 2.08 倍

- 实际步间隔：7.24 → 3.47 s
- 吞吐：13.27 → 27.66 样本/s
- 峰值已分配显存：53.31 → 53.31 GiB
- 两种后端均完成 40 个更新，loss/梯度有限
- 10 项 NPU 数值测试通过
- 8 卡 FSDP2 + 检查点重计算梯度对照通过

完整长跑与 RoboTwin 成功率尚未评测。