第三轮优化：减少小算子与同步开销

默认训练脚本已接入验证通过的优化。保持 micro batch 12、global batch 96、Muon、学习率调度与模型结构，采用本机 torch_npu 2.6 / CANN 8.2 已有能力。

+7.6%
实际训练吞吐提升

2.462 s
默认配置每次更新耗时

−13.7%
每卡每步 kernel 数量

同条件训练对照

运行	实际秒/步	样本/秒	退出码
第二轮默认 / 基线	2.6500	36.23	0
第三轮候选 • 120 步	2.5125	38.21	0
最终配置 • 132 步	2.4625	38.98	0



统一取第 31–110 步：用 step 110 与 step 30 日志时间差除以 80，包含数据等待；时间戳量化误差约 ±0.0125 s/步。最终运行在第 121–124 步采样，测速窗口未进入 profiler 采集。

具体修改

位置	修改与作用
Muon 专家权重	同形状的 3D 本地专家权重合批执行 Newton–Schulz；每个专家仍独立归一化，保留动量与状态结构。每批输入最多 32 MiB，单个参数除外。
RMSNorm / AdaNorm	在原有模块内部使用 `torch_npu.npu_rms_norm` 融合 FP32 计算；保留 FiLM、权重键和原有低精度转换顺序。
位置元数据	整数索引集中在 CPU 生成，减少循环读取 NPU 标量；修复视觉位置缓存重复计算，并在网格或 batch 变化时失效。
video teacher	缓存 RGB 均值/方差与形状决定的序列边界，减少每步重复创建设备常量。缓存不包含图像、特征或训练结果。
FSDP2 对照	实现按 QKV/输出两阶段顺序的显式预取并单独对照：开启 2.4500 s/步，关闭 2.4625 s/步。差异仅 0.5%，未超出短程波动，最终默认关闭。

验证结果与适用边界

数值、状态与运行验证

21 项 NPU 检查、44 项启动脚本检查通过；双卡 DTensor Muon 更新和旧优化器状态恢复通过，两阶段 FSDP 预取前后向对照通过。120 步候选及预取开/关两组 132 步验证均正常结束。最终脚本使用与关闭预取试验相同的有效配置。

不带 profiler 的候选峰值分配显存为 50.48 GiB，基线为 50.61 GiB（仅 rank 0 allocator 统计）。

融合计算产生浮点舍入差异，完整轨迹并非逐位一致。最终配置前 120 步对照的 loss 最大绝对差为 0.001709，梯度范数最大相对差为 4.38%。上述短程验证不替代完整 epoch 收敛与机器人任务成功率评估。

8 卡 profiler 复查

指标	优化前	优化后
每卡每步 kernel 数	42,602	36,747
Muon 主机范围	328.2 ms	224.4 ms
Newton–Schulz 主机范围	145.5 ms	55.2 ms
video teacher 主机范围	212.3 ms	73.1 ms
设备空闲范围	988.6 ms	717.7 ms
未重叠通信范围	990.1 ms	1049.9 ms
BatchMatMulV2 次数/步	2,115	840
RmsNorm 次数/步	0	73
RmsNormGrad 次数/步	0	73

两次均为 Level1、PipeUtilization、8 卡、第 121–124 次更新。主机范围包含异步提交与等待，存在嵌套和重叠，不能相加作为端到端节省时间；kernel 时间和通信等待也不等于算力利用率。

该窗口的 8 卡 AI Core 采样均值：20.0% → 19.5%。这是 npu-smi 轮询值，不是 MFU；短窗口采样会受波动影响。

> 端到端更新时间下降 7.1%。剩余开销仍包含分片通信、teacher 几何恢复和小算子调度；本轮没有消除所有低利用率原因。除 FSDP 预取外，各项收益未做独立消融，报告给出整组修改的实测效果。

网络调研如何用于本轮

昇腾官方融合算子示例：采用现有 RMSNorm 接口，并用本机数值测试验证。MindSpeed FSDP2 调优文档：参考显式预取，再按本模型两阶段调用调整。

Triton-Ascend 兼容说明及第三方 Triton Muon 实现用于评估后续方案，未引入当前环境。现有 NpuFusedAdamW 的存储合并需要额外适配 DTensor；本轮保留已验证的 AdamW foreach。

复现开关：`LINGBOT_MUON_LOCAL_BATCH=8`、`LINGBOT_HOST_METADATA=1`、`LINGBOT_NPU_FUSED_RMSNORM=1`、`LINGBOT_FSDP_FORWARD_PREFETCH=0`。设为 0 可关闭对应可选优化。